Resiliente Kommunikation durch Social Media Monitoring und Validierung

Data Week Leipzig, 15. April 2024

Rolf Fricke, Jan Thomsen, Ali Sarioglu, Marie Sophie Funk (Condat AG)





Beispiel: Großbrand im Grunewald

Berliner Feuerwehr @ @Berliner Fw - Aug 4

Bahnverkehr ist komplett eingestellt.

Update: 15.000 qm Waldfläche brennen. Auch der Sprengplatz Grunewald ist betroffen. Es kommt zu Explosionen. Ein Sperrradius von 1000m wurde

festgelegt, die BAB_A_115 ist komplett gesperrt, der angrenzende



Social Media Monitoring zur Gewinnung zusätzlicher, validierter Informationen in Krisensituationen

- Erkennung von Gefahren
- Betroffene Gebiete
- Zusätzliche Bilder und Videos
- Stimmungslage
- Meinungen aus der Bevölkerung

Zielgruppen

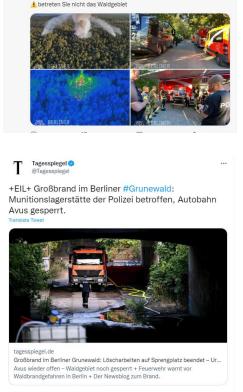
- Feuerwehr
- TV / Sender perspektivisch:
- THW
- Polizei
- weitere BOS ...



₿ Bundesanstalt THW 🥑 @THWLeitung · Aug 5

Deutschlandweite Brandeinsätze des #THW: Beim Brand auf dem Munitionsgelände im Berliner #Grunewald unterstützen THW-Einsatzkräfte mit

großen Wasser-Pufferbecken, Kraftstofflogistik und Beleuchtung. @BMI_Bund @RegBerlin @Berliner_Fw ...



6:22 AM · Aug 4, 2022 · TweetDeck



Social Media Monitoring

condat®



Quellen







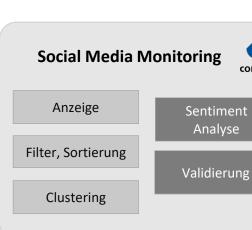
kritisches

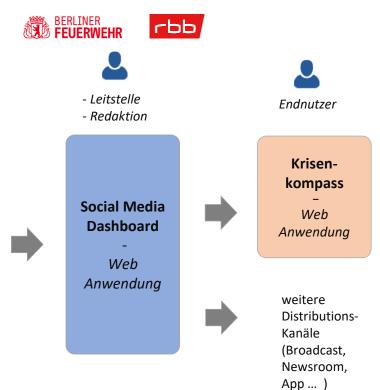
Ereignis

Suche









Social Media – Monitoring Modus



und Metrofahrten in Amsterdam erfasst.

Casana Maria - INNAVALLA A SILON

unterwegs sind, Johnt es sich, den Himmel im Blick

Glaubwürdigkeit

Auf der #A115 (AVUS) laufen von 20:00-ca. 05:00

Wohngebäude, #Brandbekämpfung und

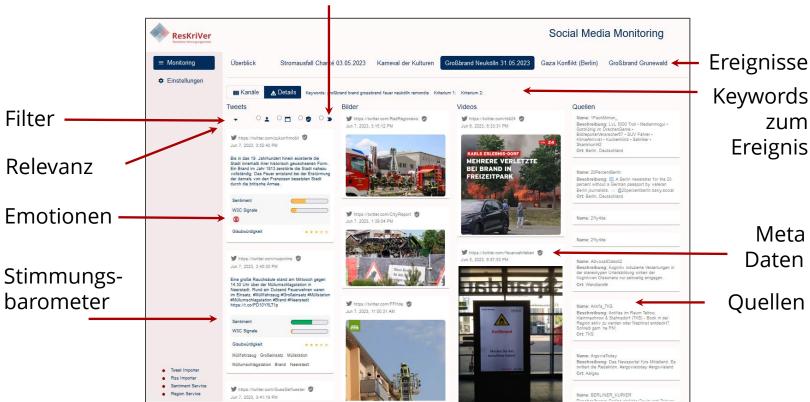
Personenrettung sind eingeleitet. Zur Zeit sind wir

Glaubwürdigkeit

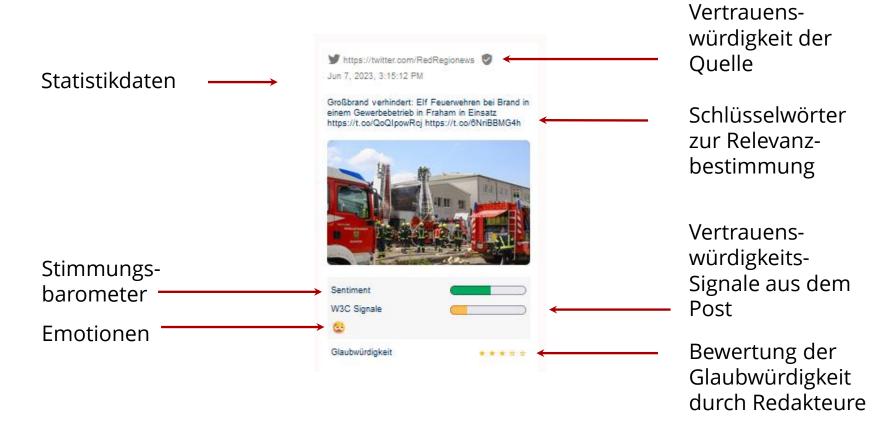
Rss Importer

 Sentiment Service Region Service

Sortierung nach Datum, Relevanz, Glaubwürdigkeit, Quellen



Analyse und Bewertung eines Posts



Einrichtung und Konfiguration durch Redaktionen

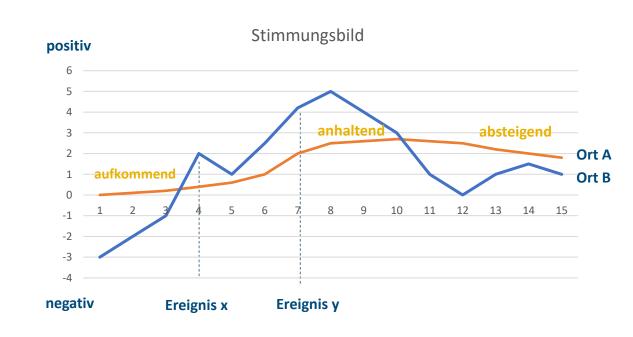




Vision: Stimmungsbild / Sentiment Analyse



- Ermittlung Stimmungsbild durch emotional positiv / negativ bewerteten Wörter / Ausdrücke
- Veränderung der Stimmungslage
- Korrelation zu Ereignissen
- Klassifikation nach: Trauer, Wut, Furcht, Freude, Überraschung, Ekel, Verachtung
- Shitstorm-Ermittlung, orts- und zeitbasiert







Sentiment Analyse

Wörterbuchbasiert

"Feierabend. Ich will nach Hause, Zug, fällt aus, das Stellwerk ist kaputt. Bus auch schlecht, da schwerer Unfall und alles gesperrt ist. Wünscht mir Glück!"

Wort	Sentiment		
abbauen	-0,2667		
Abendrot	0,8		
Fähigkeit	0,5392		
fallen	-0,3529		
Glück	0,8725		
Tisch	-0,7667		
schlecht	-0,7833		
Unfall	0,2549		
wollen	0,23		





Sentiment Analyse

Wörterbuchbasiert

"Feierabend.

Ich will nach Hause, Zug, fällt aus, das Stellwerk ist kaputt. Bus auch schlecht, da schwerer Unfall und alles gesperrt ist. Wünscht mir Glück!"

Gesamtsentiment:

$$\frac{0,2549 + (-0,3529) + (-0,7667) + (-0,7833) + 0,8725}{5} = -0,1551$$

Wort	Sentiment		
abbauen	-0,2667		
Abendrot	0,8		
Fähigkeit	0,5392		
fallen	-0,3529		
Glück	0,8725		
Tisch	0,8725		
schlecht	-0,7667		
Unfall	-0,7833		
wollen	0,2549		





Sentiment Analyse - Emotionen

Wörterbuchbasiert

"Feierabend.
Ich will nach Hause, Zug, fällt aus, das Stellwerk ist kaputt.
Bus auch schlecht, da schwerer
Unfall und alles gesperrt ist.
Wünscht mir Glück!"

Ekel	Freude	Furcht	Trauer	Überraschung	Verachtung	Wut
Bazille	Applaus	bangen	Abschied	aufschrecken	Abklatsch	Angriff
brechen	betören	grauen	Ende	Entsetzen	charakterlos	Gebrüll
Fäule	Glück	höllisch	freudlos	Knall	Dulli	hassen
igitt	Jubel	Krebs	mies	mitreißen	kaputt	pissig
speien	prima	scheu	Schmerz	radikal	schlecht	sauer
würgen	zujubeln	Unfall	Unfall	Unfall	Trottel	Vorwurf





Sentiment Analyse - Emotionen

Wörterbuchbasiert

"Feierabend.
Ich will nach Hause, Zug, fällt aus, das Stellwerk ist kaputt.
Bus auch schlecht, da schwerer Unfall und alles gesperrt ist.
Wünscht mir Glück!"

<u>Emotionen:</u> Freude, Furcht, Trauer, Überraschung, Verachtung

Ekel	Freude	Furcht	Trauer	Überraschung	Verachtung	Wut
Bazille	Applaus	bangen	Abschied	aufschrecken	Abklatsch	Angriff
brechen	betören	grauen	Ende	Entsetzen	charakterlos	Gebrüll
Fäule	Glück	höllisch	freudlos	Knall	Dulli	hassen
igitt	Jubel	Krebs	mies	mitreißen	kaputt	pissig
speien	prima	scheu	Schmerz	radikal	schlecht	sauer
würgen	zujubeln	Unfall	Unfall	Unfall	Trottel	Vorwurf



Sentiment Analyse über Generative KI



Sentiment Analyse mit generativer KI durch natürlichsprachliche Formulierung der Anfrage an das OpenAI API:

Antworte mit folgendem JSON Objekt: { "totalSentiment": 0, "emoji": Emoji, "explanationSentiment": [string] } Analysiere die Stimmung im Text mit totalSentiment: Wert für Stimmung von -1 bis 1, emoji: Emoji für Stimmung, explanation: Maximal 3 Stichwörter(Adjektive) auf deutsch für Stimmung. Alle Werte Null wenn kein Text.



positiv

negativ







positiv und negativ

https://twitter.com/BZ_NachtFloh
May 31, 2023, 12:38:44 PM

Mehr als eine halbe Million Besucher haben am Pfingstwochenende in Kreuzberg und Neukölln den Karneval der Kulturen gefeiert – auf den Straßen und in den Parks. Ausgelassenheit und Freude auf der einen, Müll und Zerstörung auf der anderen Seite. https://t.co/XgongsaWfc

Sentiment

- Ausgelassenheit Freude
- Zerstörung
- Zerstörung
- Freude
- 😖 Müll

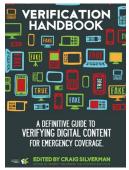




Validierung der Glaubwürdigkeit durch W3C Signals



- Training für Validierungsprozess durch Best Practice von Journalism Center (Verification Handbook), First Draft News, EU Disinfo Lab ...
- Nutzung von Standardtools für Suche, Mapping Services, Reverse Image Search, ...
- immer Nutzer in der Schleife, um die Ergebnisse der Tools zu bewerten
- Iterative Verbesserung von Tools z.B. für Deep Fake
 Detection, Audio Analyse ...











Formale Bewertung der Glaubwürdigkeit

von Posts durch ca 130 W3C Credibility Signals:

- Hasssprache, Beleidigungen, Schimpfwörter
- Grammatik- / Rechtschreibfehler
- Emotionalität, Subjektivität
- Ausrufe, Großschreibung
- Vokabularbreite
- Lesbarkeits-Indikator (z.B. Flesch-Kincaid Level)
- Konsistenz von Titel, Zusammenfassung und Inhalt

• • • •



EU Digital Services Act (DSA) - ratifiziert Feb 2024 für große Plattformen



- Entfernung von illegalen Inhalten und Hass-Kampagnen durch Plattform Operator
- weniger relevant für ResKriVer:
 - Option ohne Profil, Kündigungsoption
 - Dark Pattern, zielgerichtete Werbung bzgl.
 Religion, ethnischer Herkunft ..., Rachepornos
 - gefälschte Waren ...





─ Howden Lucas @z0ff · Aug 5

Ich kapiere diesen Schwachsinn sowieso nicht - mitten im **#Grunewald** ein **#Sprengplatz** - da lagern sie auch noch seit ewigen Zeiten anscheinend 'marode **#Weltkrieg** s-Bomben' und **#Feuerwerk** s-Gedöns.

Im Wald.

Diese Idiotie wird noch als 'alternativlos' bezeichnet. #ihrNervtNurNoch



Auf die Gefahr ungerecht zu sein, aber die Berichte über den Brand des #Grunewald.s in der @rbbabendschau finde ich verstörend: Hunderte von Einsatzkräften und schwere Technik vor Ort scheinen vor allem mit perfekten Selbstschutz beschäftigt zu sein, nicht mit Löschen.

Der .. Translate Tweet

8:42 PM · Aug 4, 2022 · Twitter for iPhone



Anforderungen des DSA (Digital Services Act) der EU



- Wie kann man zwischen kritischer Meinungsäußerung und illegaler Hassrede unterscheiden?
- Viele Posts sind nicht wahr oder falsch, legal oder illegal sondern kritische Äusserungen, wie z.B. zu "Corona-Maßnahmen" oder "Impfnebenwirkungen"
- Gefahr, dass Redaktionen sicherheitshalber zu viel löschen





DSA Krisenreaktionsmechanismus der EU (Artikel 36)



- im Krisenfall ist nach DSA ausschließlich EU-Kommission zuständig
- z.B. bei terroristischen Handlungen, Naturkatastrophen wie Erdbeben, Wirbelstürme,
 Pandemien
- Vorgaben der EU für Anbieter sehr großer Online-Plattformen:
 - Verfahren zur Moderation von Inhalten
 - Zusammenarbeit mit vertrauenswürdigen Hinweisgebern
 - Förderung vertrauenswürdiger Informationen
 - Anpassung algorithmischer Systeme
 - Änderung der AGBs



Einschränkung der Meinungsfreiheit?



- Einflussnahme von Regierungen aufgrund DSA Artikel 36 oder durch DSA Moderationsregeln
 - Beispiel: Twitter Files von Elon Musk: X/Twitter folgt Vorgaben von Regierungen (Türkei Erdogan Wahl, BRD /Corona Politik, Ukraine ...)
- -> Risiken, dass Meinungsvielfalt eingeschränkt wird
 - aufgrund DSA werden Operator im Zweifelsfall löschen um Strafen aus dem Weg zu gehen
 - Diskriminierung von Kritik, vor allem von Randgruppen und kritischen Nachfragen -> Ende des freien Internets ?



weitere EU Regulierungs Maßnahmen



- EU Al Act verabschieded Dez 2023
 - KI Algorithmen zur Klassifikation, Bewertung (kein Bias / Diskriminierung), Social Scoring unter Nutzung personenbezogener Daten
- EU Data Act verabschieded Nov 2023
 - Offenlegung von Daten gegenüber Behörden im Krisenfall
- EU Market Act ratifiziert seit Oktober 2022
 - Regelungen zu Gatekeeper Problematik

• • • •



Social Media Netzwerke sind volatil



- Aktuelle, relevante Social Media Posts für BOS primär nur auf Twitter
- Auf vielen Plattformen nicht alles sichtbar, Untergruppen z.B. nur über bestimmte Accounts (Facebook, Telegram, vk)
- Häufig wechselnde Bedingungen für Kosten und Zugriffsrechte bei Twitter API
- Bei Twitter nur für verified / bezahlte Accounts, Anzahl der Aufrufe begrenzt (z.B. 10.000 Zugriffe / Tag)

Vielen Dank für die Aufmerksamkeit!

Fragen?